

02

Enterprise Policy RAG

AI 백엔드 / RAG /
권한 검색 / 운영 관측

ROLE

2026.05-2026.06 /
개인 프로젝트 / AI
백엔드, 운영 콘솔, 검증
문서화

SKILLS

RAG
권한 필터
근거 답변
운영 관측


STACK

- Python API
- React/Vite
- PostgreSQL/pgvector
- OpenAI 선택 경로
- Vercel static demo

PROJECT 02 · AI 백엔드

권한 경계와 근거 응답을 함께 지키는 사내 정책 RAG

권한이 없는 문서의 검색 노출과 근거 없는 답변을 막기 위해 검색 전 권한 필터, 인용·거절 응답, 질의 비용·지연 추적을 갖춘 사내 정책 RAG를 구현했습니다.



01 해결한 문제

권한이 없는 문서가 검색되거나 근거가 부족한 답변이 생성되는 문제
기업 내부 정책 RAG는 검색 품질만으로 부족합니다. 사용자가 볼 수 없는 문서가 검색 후보에 섞이지 않아야 하고, 답변에는 근거가 남아야 하며, 근거가 부족한 경우 거절 응답을 반환해야 합니다.

02 핵심 설계 판단

01	02	03
Authorization first 답변 생성 전에 접근 가능한 chunk만 검색 후보로 제한	Evidence policy citation이 없으면 refusal을 반환하고 LLM 호출을 생략	Replaceable boundary provider와 repository를 분리해 기본·외부 경로를 교체

03 대표 코드 근거

RetrievalService.retrieve

app/retrieval.py

```
access_reason = _access_reason(chunk, query)
if access_reason is None:
    continue
```

저장소 필터 뒤에도 워크스페이스·소유자·부서 가시성을 다시 판정해 비인가 결과를 제거합니다.

TEST test_retrieval_allows_public_owner_and_depa...

AnswerService.answer

app/answer.py

```
if not citations:
    return AnswerResponse(
        query=query.query,
        answer=None,
        citations=[],
        refusal_reason="insufficient_evidence",
    )
```

인용 근거가 없으면 provider 호출 없이 명시적인 거절 응답을 반환해 근거 없는 답변을 막습니다.

TEST test_answer_api_refuses_when_no_evidence_is...

run_eval

app/evaluation.py

```
cases = [_run_case(services, request.workspace_id, case) for case in GOLDEN_CASES]
retrieval_hit_rate = _rate(case.retrieval_hit for case in cases)
citation_coverage = _rate(case.citation_covered for case in cases)
```

고정 평가 케이스를 실제 답변 경로로 실행해 검색 적중률과 인용 커버리지를 함께 계산합니다.

TEST test_eval_run_api_returns_retrieval_and_cit...

04 검증 결과

- 권한 검색 테스트에서 문서 5개 중 허용 범위 3개만 반환하고 다른 workspace 결과는 0건으로 고정합니다.
- 근거가 없으면 answer=null, citations=[]을 반환하고 provider 호출을 생략합니다.
- 권한 밖 보안 문서가 검색 결과와 citation에 포함되지 않는 API 시나리오를 검증합니다.

OUTCOME

권한 밖 문서를 검색·인용에서 차단하고, 근거가 없으면 provider 호출 없이 거절 응답을 반환합니다.

VERIFIED SCOPE

기본 경로는 메모리 저장소와 정적 데모로 검증했으며 PostgreSQL/pgvector·OpenAI live 경로와 운영 인증은 선택 검증으로 분리했습니다.