

04

AI Gateway

LLM Gateway /
라우팅 / 비용 보호 /
캐시 / 폴백 / 관측

ROLE

2026.06 / 개인
프로젝트 / AI 백엔드
· LLM 플랫폼 설계, 구현,
검증

SKILLS

LLM Gateway
비용 보호
캐시/폴백
WebFlux

STACK

Java 21

Spring Boot WebFlux

Redis


PostgreSQL/pgvector

Testcontainers

PROJECT 04 · LLM Gateway

LLM 호출 정책과 장애 대응을 공통화한 OpenAI 호환 Gateway

OpenAI 호환 WebFlux 진입점에 API key 인증, tenant별 할당량·예산, exact-semantic cache, 정책 routing, circuit breaker·요청 추적을 단일 pipeline으로 구현했습니다.



01 해결한 문제

서비스마다 중복되는 LLM 정책과 provider 장애 대응

LLM 기능을 여러 애플리케이션에 붙이면 provider SDK, 장애 대응, 토큰·비용 예산, 캐시, 보호 규칙, 요청 관측이 서비스마다 중복됩니다. Gateway가 공통 정책과 관측을 처리하도록 구조를 모았습니다.

02 핵심 설계 판단

01	02	
Compatible entry OpenAI 호환 /v1/chat/completions로 클라이언트 변경 최소화	Policy pipeline auth·quota·guard·cache·router·fallback·record 순서 고정	Bounded resilience retry budget·circuit breaker·fallback chain으로 복구 범위 제한

03 대표 코드 근거

GatewayPipeline.execute

.../gateway/api/GatewayPipeline.java

```
QuotaOutcome quota = quotaGuard.evaluate(request, estimatedTokens);  
if (quota != QuotaOutcome.ALLOWED) {  
    return rejected(request, mode, quota, elapsed(start));  
}
```

예산 토큰으로 tenant 할당량을 먼저 검사해 초과 요청을 provider 호출 전에 종료합니다.

TEST RequestLogStoreTest

TwoStageCache.lookup

.../gateway/cache/TwoStageCache.java

```
if (exactLookup.hit()) {  
    return exactLookup;  
}  
return semantic.lookup(request);
```

동일 요청은 exact cache에서 반환하고 miss일 때만 semantic cache로 확장합니다.

TEST TwoStageCacheTest

FallbackChain.dispatch

.../gateway/resilience/FallbackChain.java

```
lastErrorType = RETRY_BUDGET_EXHAUSTED;  
events.add(FallbackEvent.failed(attempt, candidate.provider(), candidate.model(),  
lastErrorType));  
return FallbackResult.ofFailure(attempt, lastErrorType, events);
```

재시도 예산이 소진되면 다음 provider 호출을 차단하고 관측 가능한 실패 이벤트를 남깁니다.

TEST FallbackChainTest

04 검증 결과

- ChatCompletionController 테스트
buffered 응답과 SSE streaming 검증합니다.
- 인증 누락 401, 잘못된 요청 400,
quota-budget 보호 규칙을 API 테스트
고정합니다.
- PolicyRouter와 pipeline 테스트가
routing, tool-call passthrough, c
fallback 순서를 확인합니다.

OUTCOME

앱별 LLM 호출 코드에 흩어질 수 있는 라우팅, 비용 보호, 캐시, 폴백, 관측 기능을 Gateway 계층으로 모았습니다.

VERIFIED SCOPE

기본 검증은 고정 응답 provider와 메모리 저장소를 사용했으며 실제 p
전송·운영 저장소·클라우드 배포는 포함하지 않았습니다.