

AI Gateway

LLM Gateway / 라우팅 /
비용 보호 / 캐시 / 폴백 /
관측

담당 범위

2026.06 / 개인 프로젝트
/ AI 백엔드·LLM 플랫폼
설계, 구현, 검증

주요 기술

Java 21


Spring Boot
WebFlux

Redis

PostgreSQL/pgvec
tor

예산 초과와 외부 모델 실패를 호출 전에 통제하는 LLM 게이트웨이

서비스마다 흩어진 LLM 인증·예산·캐시·라우팅·복구 정책을 OpenAI 호환 WebFlux 게이트웨이의 한
요청 처리 순서로 통합했습니다.



해결한 문제

애플리케이션마다 중복되는 LLM 정책과 외부 모델 장애 처리

LLM 기능을 여러 애플리케이션에 붙이면 외부 모델 SDK, 장애 대응, 토큰·비용 예산,
캐시, 보호 규칙과 요청 기록이 서비스마다 따로 구현됩니다. 게이트웨이가 공통 정책과
요청 기록을 처리하도록 구성했습니다.

핵심 설계 판단

공통 호환 API

OpenAI 호환 /v1/chat/completions로
클라이언트 변경 최소화

고정된 정책 순서

인증·할당량·입출력 검사·캐시·라우팅·복구·기록
순서 고정

대표 코드 근거

GatewayPipeline.execute

파일 backend/src/main/java/com/example/gateway/api/GatewayPipeline.java

```
QuotaOutcome quota = quotaGuard.evaluate(request,
estimatedTokens);
if (quota != QuotaOutcome.ALLOWED) {
    return rejected(request, mode, quota,
elapsed(start));
}
```

보호 규칙예상 토큰으로 사용자 조직의 할당량을 먼저 검사해 초과 요청을
외부 모델 호출 전에 종료합니다.

연결 테스트 backend/src/test/java/com/example/gateway/observability/RequestLogStoreTest.java
RequestLogStoreTest.quotaRejectPathCreatesRowWithNullProviderAndOutcome

검증 결과

- ChatCompletionController
테스트가 JSON 일괄 응답과
SSE 스트리밍 경로를 분리해
검증합니다.
- 인증 누락 401, 잘못된 요청
400과 할당량·예산 보호
규칙을 API 테스트로
고정합니다.

구현 결과

재시도 예산이 소진되면 다음 외부 모델 호출을
차단하고, 할당량 초과 요청은 모델을 호출하지 않은
채 거절하도록 검증했습니다.

확정한 범위와 남은 경계

기본 검증은 고정 응답 외부 모델과 메모리 저장소를
사용했으며 실제 모델 전송·운영 저장소·클라우드
배포는 포함하지 않았습니다.