

04

AI Gateway

LLM Gateway /
라우팅 / 비용 보호 /
캐시 / 폴백 / 관측

담당 범위

2026.06 / 개인
프로젝트 / AI 백엔드
· LLM 플랫폼 설계,
구현, 검증

핵심 역량

LLM Gateway
비용 보호
캐시/폴백
WebFlux


주요 기술

- Java 21
- Spring Boot WebFlux
- Redis
- PostgreSQL/pgvector

문제 · 설계 · 실패 조건 · 검증 결과

예산 초과와 provider 실패를 호출 전에 통제하는 LLM Gateway

서비스마다 흩어진 LLM 인증·예산·캐시·라우팅·폴백을 OpenAI 호환 WebFlux Gateway의 한 요청 파이프라인으로 통합했습니다.



01 해결한 문제

앱마다 중복되는 LLM 정책과 provider 장애 처리

LLM 기능을 여러 애플리케이션에 붙이면 provider SDK, 장애 대응, 토큰·비용 예산, 캐시, 보호 규칙, 요청 관측이 서비스마다 따로 구현됩니다. Gateway가 공통 정책과 관측을 처리하도록 구조를 모았습니다.

02 핵심 설계 판단

01	02	03
Compatible entry OpenAI 호환 /v1/chat/completions로 클라이언트 변경 최소화	Policy pipeline auth·quota·guard·cache·router·fallback·record 순서 고정	Bounded resilience retry budget·circuit breaker·fallback chain으로 복구 범위 제한

03 대표 코드 근거

GatewayPipeline.execute

파일 backend/src/main/java/com/example/gateway/api/GatewayPipeline.java

```
QuotaOutcome quota = quotaGuard.evaluate(request, estimatedTokens);
if (quota != QuotaOutcome.ALLOWED) {
    return rejected(request, mode, quota, elapsed(start));
}
```

보호 규칙예산 토큰으로 tenant 할당량을 먼저 검사해 초과 요청을 provider 호출 전에 종료합니다.

연결 테스트 backend/src/test/java/com/example/gateway/observability/RequestLogStoreTest.java
RequestLogStoreTest.quotaRejectPathCreatesRowWithNullProviderAndOutcome

TwoStageCache.lookup

파일 backend/src/main/java/com/example/gateway/cache/TwoStageCache.java

```
if (exactLookup.hit()) {
    return exactLookup;
}
return semantic.lookup(request);
```

보호 규칙동일 요청은 exact cache에서 반환하고 miss일 때만 semantic cache로 확장합니다.

연결 테스트 backend/src/test/java/com/example/gateway/cache/TwoStageCacheTest.java
TwoStageCacheTest.differentlyWordedSimilarPromptFallsThroughToSemanticHit

FallbackChain.dispatch

파일 backend/src/main/java/com/example/gateway/resilience/FallbackChain.java

```
lastErrorType = RETRY_BUDGET_EXHAUSTED;
events.add(FallbackEvent.failed(attempt, candidate.provider(),
candidate.model(), lastErrorType));
return FallbackResult.ofFailure(attempt, lastErrorType, events);
```

보호 규칙재시도 예산이 소진되면 다음 provider 호출을 차단하고 관측 가능한 실패 이벤트를 남깁니다.

연결 테스트 backend/src/test/java/com/example/gateway/resilience/FallbackChainTest.java
FallbackChainTest.exhaustedBudgetBlocksFallbackWithoutCallingProvider

04 검증 결과

- ChatCompletionController 테스트가 JSON buffered 응답과 SSE streaming 경로를 분리해 검증합니다.
- 인증 누락 401, 잘못된 요청 400, quota·budget 보호 규칙을 API 테스트로 고정합니다.
- PolicyRouter와 pipeline 테스트가 weighted routing, tool-call passthrough, cache 우회와 fallback 순서를 확인합니다.

구현 결과

앱별 LLM 호출 코드에 흩어질 수 있는 라우팅, 비용 보호, 캐시, 폴백, 관측 기능을 Gateway 계층으로 모았습니다.

확인한 범위와 남은 경계

기본 검증은 고정 응답 provider와 메모리 저장소를 사용했으며 실제 provider 전송·운영 저장소·클라우드 배포는 포함하지 않았습니다.