

05

CDC Data Platform

CDC / Kafka / Lakehouse / Lineage / Replay

담당 범위

2026.06 / 개인 프로젝트 / CDC 데이터 플랫폼 백엔드 설계, 구현, 검증

핵심 역량

CDC
Kafka 복구
Lineage
Lakehouse


주요 기술

- Spring Boot
- PostgreSQL
- Debezium
- Kafka

문제 · 설계 · 실패 조건 · 검증 결과

변경 캡처·복구·저장을 독립 경계에서 검증한 CDC 플랫폼

PostgreSQL 변경 캡처, canonical event 제어, lakehouse 저장을 세 독립 실험으로 구현했습니다. 각 경계에서 source metadata, 중복 ledger, replay 상태와 lineage fixture를 검증했습니다.



01 해결한 문제 중복 CDC, 복구 이력 손실, 연결되지 않은 구간의 보장 과정
CDC 이벤트는 connector 재시작과 재전달로 중복될 수 있고 sink 실패 뒤 복구 이력이 사라질 수 있습니다. runtime-제어면-lakehouse가 아직 자동 연결되지 않은 상태에서도 각 경계의 보호 규칙과 검증 결과를 구분할 필요가 있었습니다.

01	02	03
Metadata-derived ID LSN-offset를 event ID와 replay-lineage 기준으로 사용	복구 상태 분리 raw-canonical-retry-DLQ-replay 상태를 분리해 원인과 재처리를 추적	독립 검증 경계 runtime-control plane-lakehouse 사이의 미연결 구간을 명시하고 각 fixture 결과만 주장

03 대표 코드 근거 **04 검증 결과**

```
CanonicalIngestService.ingestRawEnvelope
파일 backend/src/main/java/com/example/cdcplatform/event/CanonicalIngestService.java

DebeziumEnvelope envelope = DebeziumEnvelope.parse(rawEnvelopeJson);
CanonicalCdcEvent event = CanonicalCdcEvent.fromEnvelope(envelope);
String sourceOffsetJson = sourceOffsetJson(envelope);
boolean created = canonicalEventPublisher.recordCanonicalEvent(event, sourceOffsetJson);

보호 규칙Debezium 원본을 표준 이벤트로 정규화하면서 source offset을 보존하고 ledger 결과로 중복을 판정합니다.
연결 테스트 backend/src/test/java/com/example/cdcplatform/event/CanonicalIngestServiceTest.java
CanonicalIngestServiceTest.duplicateRawEnvelopeDoesNotIncreaseCanonicalEventCount

ReplayRequestService.requestReplay
파일 backend/src/main/java/com/example/cdcplatform/replay/ReplayRequestService.java

DlqEventRepository.DlqEvent dlqEvent = dlqEventRepository.findById(dlqEventId)
.orElseThrow(() -> new IllegalArgumentException("DLQ event not found: " + dlqEventId));
String requestId = "replay_" + UUID.randomUUID();

보호 규칙존재하는 DLQ 이벤트만 replay 대상으로 허용하고 요청 추적용 고유 ID를 생성합니다.
연결 테스트 backend/src/test/java/com/example/cdcplatform/replay/ReplayRequestServiceTest.java
ReplayRequestServiceTest.createReplayRequestAndMarksDlqEventForReplay

IcebergJavaEngine.append
파일 tools/iceberg-engine/src/main/java/com/example/cdcplatform/tools/IcebergJavaEngine.java

DataFile dataFile = writer.toDataFile();
table.newAppend().appendFile(dataFile).commit();
table.refresh();
Snapshot snapshot = table.currentSnapshot();

보호 규칙Parquet data file을 Iceberg append로 commit하고 현재 snapshot을 다시 조회해 적재 이력을 남깁니다.
연결 테스트 tools/tests/test_lakehouse_smoke.py
LakehouseSmokeTest.test_iceberg_engine_append_passes_insert_sql_and_writes_data_file
```

- local lineage fixture가 raw event 7건 중 6건을 적용하고 duplicate 1건을 억제합니다.
- applicant-job-evaluation-agent task 4개 source table의 metadata와 lineage key를 보존합니다.
- lineage fixture 2개 중 1개 complete path를 식별하고 incomplete 경로를 분리해 보고합니다.

구현 결과 변경 캡처에서는 operation-LSN-offset을, 제어면에서는 event ID-ledger-복구 상태를, lakehouse fixture에서는 object key와 lineage 완료 여부를 각각 추적합니다.

확인한 범위와 남은 경계 CDC runtime, control plane, lakehouse는 독립 프로토타입입니다. A의 Kafka topic을 B가 상시 소비하거나 B의 결과가 C로 자동 전달되는 경로와 AWS S3/Athena-Trino 실행은 검증하지 않았습니다.